



ugr

Universidad
de Granada

TRABAJO FIN DE GRADO
INGENIERÍA EN TECNOLOGÍAS DE TELECOMUNICACIÓN

Controlador Neuronal

Esquemas de aprendizaje de modelos internos de brazo
robótico con múltiples articulaciones

Autor

Julio Jesús Vizcaíno Molina

Directores


Jesús Garrido Alcázar

Eva Martínez Ortigosa



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, hoy de 2016



Controlador Neuronal

Esquemas de aprendizaje de modelos internos de brazo
robótico con múltiples articulaciones

Autor

Julio Jesús Vizcaíno Molina

Directores

Jesús Garrido Alcázar

Eva Martínez Ortigosa

Controlador Neuronal: Esquemas de aprendizaje de modelos internos de brazo robótico con múltiples articulaciones

Julio Jesús Vizcaíno Molina

Palabras clave: robot_controller, neural_networks, deep_learning, baxter_robot

Resumen

Calcular el modelo dinámico de un brazo robótico es la mejor manera de entender y diseñar un controlador para dicho brazo. Sin embargo, es una tarea complicada que se basa en el conocimiento del funcionamiento del robot, así como de sus características. El controlador que aquí se presenta resuelve estos problemas. Se basa en el auto-aprendizaje del modelo, así como de los parámetros del robot. Para ello hace uso de técnicas de aprendizaje automático (Deep Learning). Estas redes son sistemas de propósito general que parametrizan variables internas en la fase de entrenamiento, para así obtener un modelo concreto al final de esta fase. Este modelo es capaz de desempeñar el papel del controlador empleado para modelarlo sobre datos no visto antes.

Neural Controller: Project Subtitle

Julio Jesús Vizcaíno Molina

Keywords: Keyword1, Keyword2, Keyword3,

Abstract

Write here the abstract in English.

Yo, **Julio Jesús Vizcaíno Molina**, alumno de la titulación Grado en Ingeniería de Tecnologías de Telecomunicación de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 77151856n, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Julio Jesús Vizcaíno Molina

Granada a hoy de este mes de 2016

D. **Jesús Garrido Alcázar**, Profesor del Área de Arquitectura y Tecnología de Computadores del Departamento Arquitectura y Tecnología de Computadores de la Universidad de Granada.

D.^a **Eva Martínez Ortigosa**, Profesora del Área de Arquitectura y Tecnología de Computadores del Departamento de Arquitectura y Tecnología de Computadores de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado *Controlador Neuronal, Esquemas de aprendizaje de modelos internos de brazo robótico con múltiples articulaciones*, ha sido realizado bajo su supervisión por **Julio Jesús Vizcaíno Molina**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a X de mes de 201 .

Los directores:

Jesús Garrido Alcázar

Eva Martínez Ortigosa

Agradecimientos

Poner aquí agradecimientos...

Índice general

1. Introducción	15
1.1. Motivación	15
1.2. Objetivos	15
1.3. Metodología	15
2. Materiales y métodos	17
2.1. ROS	17
2.1.1. Arquitectura	17
2.1.2. rosbag	18
2.2. Baxter	19
2.2.1. Hardware	19
2.2.2. Disposición	20
2.2.3. Modos de control	21
2.2.4. API de ROS	22
2.2.5. API de Python	23
2.2.6. Mecanismos de control	23
2.2.7. Simuladores	27
2.3. Redes Neuronales	27
2.3.1. Topología	28
2.3.2. Regularización	33
2.3.3. Aprendizaje profundo	34
2.3.4. Evaluación	35
2.3.5. Herramientas	35
2.4. Controladores	36
2.4.1. Error distal	36
2.4.2. Control realimentado	36
2.4.3. Control Anticipativo	36
3. Diseño experimental y resultados	37
3.1. Diseño experimental	37
3.1.1. Extracción de base de datos	37
3.1.2. Red Neuronal	40
3.2. Resultados	41

3.2.1. Base de datos	41
4. Conclusiones	43
4.1. Trabajo realizado	43
4.2. Objetivos alcanzados	43
4.3. Trabajo futuro	43
Bibliografía	46

Capítulo 1

Introducción

1.1. Motivación

1.2. Objetivos

Los objetivos del trabajo son los siguientes:

1. Estudio de los mecanismos de control implementados en el robot biomórfico Baxter.
2. Caracterización y obtención de una base de datos de movimientos utilizando los controladores incluidos en el robot.
3. Estudio de la viabilidad de implementación de un sistema de control adaptativo basado en técnicas de machine learning.

1.3. Metodología

Capítulo 2

Materiales y métodos

2.1. ROS

ROS (Robot Operative System) [7] es un sistema operativo de código abierto basado en paso de mensajes diseñado para plataformas robóticas. Sus usos van desde el diseño de drivers, a resolver problemas complejos como la navegación autónoma.

La filosofía del sistema operativo es permitir a los desarrolladores abarcar de manera independiente los problemas que surgen al desarrollar una plataforma robótica, de modo que cada módulo pueda comunicarse con el resto, y que no haya que rediseñar un programa cuando se quiere cambiar de plataforma (y que una misma plataforma se beneficie de la implementación de distintos programas).

La versión usada para trabajar con el robot Baxter [19] ha sido **Indigo**, ya que es la versión soportada por el robot.

2.1.1. Arquitectura

La arquitectura de ROS sigue un modelo distribuido, donde cada nodo realiza una tarea y los nodos pueden comunicarse entre sí. Esta comunicación lo hace mediante paso de mensajes.

Nodos

Los nodos son los programas que realizan las tareas, ejecutables que utilizan ROS para comunicarse con otros nodos. Para programarlos se usan las librerías *roscpp* (para c++) o *rospy* (para Python). En el presente trabajo se utiliza la implementación en Python (por motivos de compatibilidad con la interfaz de programación de aplicaciones (API) de Baxter, así como con las librerías *tensorflow* [23] y *keras* [6] explicadas más adelante).

Temas

Los temas son los canales de comunicación que utilizan los nodos para comunicarse con otros nodos. Son los “puertos” que cada tema pone a público para permitir la comunicación con otros nodos.

Los nodos publican y se suscriben a los temas.

Mensajes

La comunicación entre nodos se hace con el paso de mensajes. Estos son estructuras de datos que permiten a los nodos especificar y conocer la información que envían y reciben.

Servicios

Se trata de otra manera de comunicación, en la que un nodo hace una petición a otro y éste puede responder. Se diferencia de los mensajes en que el suscriptor puede responder al mensaje recibido, y su uso está enfocado a tareas aperiódicas.

Parámetros

Los parámetros son piezas de información contenidas en cada nodo que pueden ser vistas y modificadas por los nodos.

Ejemplo

Como ejemplo, se puede pensar en una cámara de vídeo que retransmite el vídeo en tiempo real. Esta cámara es un nodo (`/camera`) que publica mensajes del tipo imagen (que consiste en una matriz de $n \times m$ píxeles) al tema `/camera/image`.

Por otro lado, en un servidor estamos ejecutando un programa de detección de imágenes haciendo uso de ROS para la comunicación (nodo `/camera/server`). Este programa se suscribe al tema `/image` para recibir las imágenes que va a analizar.

Adicionalmente, la cámara tiene habilitado un servicio para reiniciar la cámara (`/camera/reset`) así como un conjunto de parámetros para filtrar las imágenes antes de publicarlas (`/color_mode`), que permite cambiar la imagen a blanco y negro, sepia...

2.1.2. rosbag

`rosbag` es una herramienta para grabar el paso de mensajes realizados sobre los temas que se le ofrecen como parámetros. Tiene la capacidad de grabar información adicional a los mensajes, como la marca temporal (momento en el que el mensaje es registrado) y de secuencia (número de mensaje).

en una secuencia) que cada mensaje tiene asociada. Esto es útil para sincronizar mensajes generados por otro sistema y recibidos por tcp/ip con los mensajes generados en el propio ordenador.

2.2. Baxter

El robot biomórfico Baxter se trata de un robot de bajo coste (28.000 euros) y de baja fuerza, capaz de trabajar en entornos seguros, con otras personas a su alrededor. Esto se debe al uso de motores de bajo torque, así como del uso de actuadores elásticos en serie [17].

Cuenta con un modelo de movimiento automático basado en aprendizaje de ejemplos dados por una persona, lo que permite a personal no cualificado enseñarle a realizar tareas.

2.2.1. Hardware

Estructura física

El robot cuenta con:

2 brazos Con 7 articulaciones (grados de libertad) cada uno y sensores que miden la posición, velocidad y torque aplicado en cada una de las articulaciones.

Pantalla En la cabeza, con la capacidad de moverse hacia los lados.

3 cámaras Una al final de cada brazo y una en la pantalla, con una resolución máxima de 1280 x 800 píxeles y una tasa de refresco de 30 cuadros por segundo.

Pinzas Que se colocan al final de cada articulación. También se puede colocar una bomba de vacío. No interfieren con las cámaras.

Sonar Ubicado en la cabeza.

Botones Para interactuar con el robot, ubicados en los brazos, así como en el torso, a cada lado del robot.

Las articulaciones son:

s0 Rotación del hombro.

s1 Traslación del brazo.

e0 Rotación del brazo.

e1 Traslación del antebrazo.

w0 Rotación del antebrazo.

w1 Traslación de la mano.

w2 Rotación de la muñeca, a fin de satisfacer dicho movimiento cuando la pinza se encuentra insertada.

Dichas articulaciones se pueden observar en la figura 2.1.

Procesamiento

En el interior del Baxter contamos con un procesador Intel Core i7-3770 a 3.4 GHz con tarjeta gráfica integrada, 4 GB de memoria RAM, y 128 GB de disco duro SSD.

Actuadores elásticos en serie

Los motores utilizados para las articulaciones utilizan actuadores elásticos en serie, en contraposición a los actuadores rígidos, usados en tareas de gran precisión.

Los actuadores rígidos basan su correcto funcionamiento en la cantidad de torque que pueden aplicar: a mayor torque, mayor precisión. Suelen ser controlados sin realimentación, y basan su control en un mapeo de voltajes y posiciones. Al tener tanto torque los motores, cualquier fuerza externa se vuelve despreciable, por lo que se puede confiar su control a uno basado en el conocimiento del motor.

Es este gran torque el que hace que los robots diseñados con estos motores no sean seguros para las personas. Los robots industriales en cadenas de montaje usan este tipo de actuadores.

Por otro lado, los actuadores elásticos basan su funcionamiento en la cantidad de torque que aplican, lo que significa que un controlador basado en realimentación es necesario, ya que el motor no conoce la posición en la que está, sino el torque que está aplicando. Esto lo consigue haciendo uso de elementos elásticos, los cuales aplican una fuerza sobre el objeto a mover. La posición de dicho objeto se mide y se transmite al controlador, que aplicará la fuerza correspondiente.

Los robots basados en estos actuadores son más seguros, ya que la cantidad de torque se puede controlar, ya sea por software o por la propia construcción hardware. Baxter utiliza este tipo de actuadores.

2.2.2. Disposición

Para trabajar con el robot se dispone de un laboratorio de dimensiones reducidas, teniendo en cuenta el rango de movimiento del robot y la compartición del espacio con más gente.




Figura 2.1: Articulaciones del robot Baxter

Además del robot, es necesario un equipo de trabajo, que consistirá en un ordenador de sobremesa con un procesador Intel Core i7-5930k a 3.5 GHz, 32 GB de memoria RAM y 200 GB de disco SSD y 1 TB de disco HDD.

Este equipo se usará para comunicarse con el robot, ejecutando el programa en el ordenador y transmitiendo mensajes entre el robot y éste haciendo uso de ROS .

2.2.3. Modos de control

Cada brazo se puede controlar de manera independiente, pudiendo usar cada uno de ellos con un modo de control distinto. Los modos de control son los que se muestran a continuación:

1. Control por posición
2. Control por velocidad
3. Control por torque
4. Control por posición sin procesar (raw mode)

Haciendo uso de la arquitectura de paso de mensajes que nos ofrece ROS , somos capaces de enviar en un tema (topic) tanto el modo de control que queremos usar como las características objetivos que queremos en el movimiento. El robot Baxter estará escuchando cada uno de los mensajes que le enviemos a los temas `/robot/limb/left/joint_command` para el brazo

izquierdo y `/robot/limb/right/joint_command` para el brazo derecho. El tipo de mensaje que se envía es `JointCommand`, que tiene como argumentos:

- `mode` (`POSITION_MODE=1`, `VELOCITY_MODE=2`, `TORQUE_MODE=3`, `RAW_POSITION_MODE=4`)
- `command` (lista de flotantes)
- `names` (lista de nombre de articulaciones)

El modo de control para cada brazo es único, mientras que la posición/-velocidad/torque deseado es único para cada articulación en cada brazo.

Aparte de enviar este tipo de mensajes, podemos definir la velocidad relativa máxima que alcanzará cada articulación en el modo de control por posición publicando al tema `/robot/limb/<right/left>/set_speed_ratio` un valor entre 0 y 1.

El robot Baxter cuenta con una serie de limitaciones, en cuanto a posiciones, velocidades y torques se refiere, para cada articulación. Estas limitaciones se muestran en el cuadro 2.1.

2.2.4. API de ROS

Baxter hace uso de ROS para comunicarse internamente, así como para recibir y enviar información con el exterior.

La interfaz de programación de aplicaciones (API) de Baxter con respecto a ROS pone a disposición del programador los tipos de mensajes y servicios usados por el mismo, así como de los temas publicados para su control.

En este trabajo se hace uso de los siguientes temas:

- `/robot/joint_states` Publica información tanto de la posición como de la velocidad y torque de las articulaciones de todas las articulaciones.

Cuadro 2.1: Límites articulaciones

Art.	(rad) Mín	(rad) Máx	(rad) Rango	(rad/s) Vel máx	(Nm/rad)
S0	-1.7016	+1.7016	3.4033	2.0	843
S1	-2.147	+1.047	3.194	2.0	843
E0	-3.0541	+3.0541	6.1083	2.0	843
E1	-0.05	+2.618	2.67	2.0	843
W0	-3.059	+3.059	6.117	4.0	250
W1	-1.5707	+2.094	3.6647	4.0	250
W2	-3.059	+3.059	6.117	4.0	250

- `/robot/limb/left/set_speed_ratio` Tema al que publicar para ajustar la ratio de velocidad usada por cada articulación del brazo izquierdo (única para todas).
- `/robot/limb/left/joint_command` Tema al que publicar para mover el brazo a las posiciones deseadas del brazo izquierdo (una para cada articulación).

2.2.5. API de Python

La API tiene como objetivo disponer una interfaz basada en el lenguaje de programación Python para controlar y monitorizar el robot Baxter, ejecutando en su base las correspondientes instrucciones ROS. Para ello, cuenta con una serie de módulos orientados a los distintos componentes del robot (brazos, pinzas, cámara...).

Se hará uso del módulo `brazo` para realizar el movimiento del mismo. Por motivos de disposición del robot en el laboratorio, se extraerá la base de datos haciendo uso del brazo izquierdo.

Dentro de este módulo, se hará uso de las funciones `set_joint_position_speed(speed)` y `move_to_joint_positions(positions)`. La primera controlará la velocidad máxima relativa para cada articulación, mientras que la segunda moverá el brazo a la posición deseada. Esta función cuenta además con un intervalo de tiempo máximo para realizar el movimiento. Que el tiempo máximo se agote será indicador de que el robot no puede alcanzar la posición deseada (está colisionando consigo mismo).

La función `move_to_joint_positions(positions)` realiza un filtro paso baja de la diferencia de posiciones (actual y deseada) en el tiempo, ofreciendo un movimiento más fluido.

2.2.6. Mecanismos de control

Control por posición

El control por posición consiste en alcanzar las posiciones objetivo para cada una de las articulaciones. El modo de control en el mensaje `JointCommand` es el 1.

La orden donde todas las articulaciones se ponen en la posición 0 corresponde con el brazo totalmente estirado y con el hombro, codo y muñeca mirando hacia abajo. Las traslaciones y rotaciones se corresponden con los de la figura 2.2.

Dada la naturaleza del robot Baxter, en este modo de operación se aplican unos filtros antes de aplicar la orden de posición, a fin de evitar accidentes y otorgar una experiencia de movimiento más fluida y segura. Los filtros son los que se muestran en la figura 2.3a.




Figura 2.2: Límites articulaciones

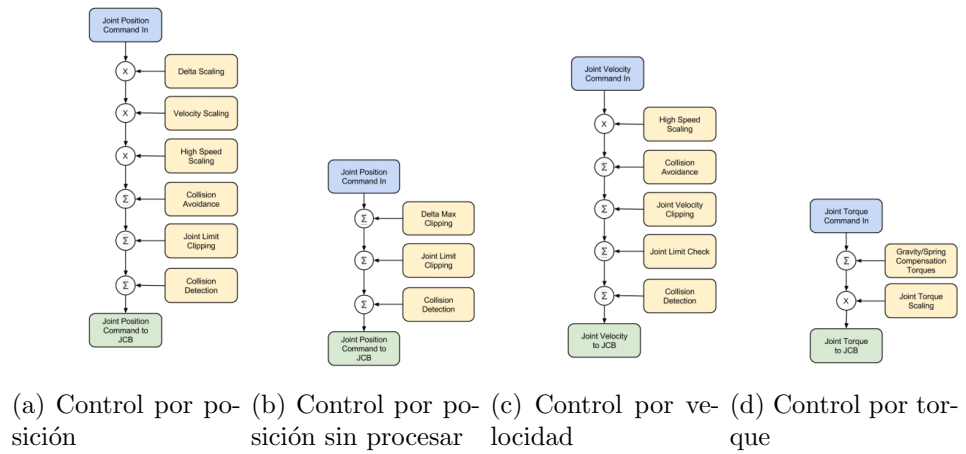


Figura 2.3: Filtros aplicados

1. Escalado delta. Consiste en escalar las posiciones objetivo en el recorrido para conseguir que todas las articulaciones lleguen al punto deseado a la vez.
2. Escalado de velocidad. Se escala la velocidad de cada articulación en función del 'ratio de velocidad'.
3. Escalado de alta velocidad. Para evitar colisiones entre los dos brazos moviéndose el uno en la dirección del otro, se escala la velocidad y recalcula la posición cuando ésta supera un umbral.
4. Prevención de colisiones. Gracias a un modelo interno del robot, se limitan las posiciones de las articulaciones tales que provocarían un choque con el propio robot.
5. Recorte de posiciones. Si las posiciones superan los límites de la articulación, estas se recortan al límite permitido.
6. Detección de colisión. Si se detecta una colisión (con un objeto externo al robot), mantiene la última posición antes de la colisión.

Como se puede observar, Baxter aplica unos filtros para evitar y detectar colisiones. Esta tarea se realiza de tres maneras:

- Prevención. El robot ejecuta una simulación interna, donde las articulaciones y el cuerpo cuentan con unas regiones de seguridad que, al tocarse, limitan el movimiento del robot.
- Detección de colisión. Esto se realiza de dos maneras

Impacto Cuando el torque de cualquier articulación cambia bruscamente, se considera que ha habido una colisión.

Retención Cuando el torque aplicado aumenta pero la articulación no se mueve, se considera que está colisionando con un objeto inmóvil.

- Escalado de alta velocidad. Cuando la velocidad del brazo supera los 0.2 m/s, las regiones de seguridad que el robot simula internamente aumentan. Cuando se tocan estas regiones, la velocidad se escala y la posición se recalcula.

Control por posición sin procesar

Este modo de control, al igual que el anterior, tiene como objetivo alcanzar la posición deseada para cada articulación. Se diferencia en los filtros que aplica (figura 2.3b).

1. Recorte de delta máximo. Recorta la posición siguiente (en el intervalo de actuación de cada articulación) a la máxima posición alcanzable a la velocidad máxima dada por la 'ratio de velocidad'.
2. Recorte de posiciones. Al igual que en el modo de control anterior, si las posiciones superan los límites de la articulación, estas se recortan al límite permitido.
3. Detección de colisión. Cumple la misma función que en el modo de control por posición.

Como se puede observar, este es un modo de control más avanzado, ya que no tiene en cuenta las colisiones consigo mismo, y ofrece un movimiento más brusco al no llegar todas las articulaciones al punto destino a la vez.

El modo de control en el mensaje JointCommand es el 4.

Control por velocidad

En este modo de control, lo que se busca es adquirir la velocidad objetivo para cada articulación. El modo de control en el mensaje JointCommand es el 2. Al igual que en los modos anteriores, se aplican una serie de filtros (figura 2.3c).

1. Escalado de alta velocidad. Como en el control por posición.
2. Prevención de colisiones. Como en el control por posición.
3. Recorte de velocidades. Se limitan las velocidades para cada articulación para que no excedan el máximo permitido.
4. Comprobación de límites. Se comprueban los límites de las articulaciones. Si se exceden, se detiene el movimiento.
5. Detección de colisión. Igual que en el control por posición.

El dejar de enviar velocidades si se exceden los límites de las articulaciones es una medida de seguridad que exige al programador tener el control sobre las posiciones que puede alcanzar el brazo.

Control por torque

El control por torque consiste en el modo de más bajo nivel que se puede controlar el robot Baxter. Los torques que enviemos serán aplicados por los controladores, haciendo uso solamente de los siguientes filtros (figura 2.3d):

1. Compensación. Los torques se suman a los necesarios para mantener la gravedad 0 y el muelle ubicado en la articulación s1 (traslación del hombro).

2. Escalado de torque. Si un torque excede el torque máximo para esa articulación, escala los torques de todas las articulaciones por el factor de exceso de esa articulación ($\text{torque_max}/\text{torque}$).

La compensación de la gravedad se puede desactivar mandando un mensaje vacío al tema `/robot/limb/right/suppress_gravity_compensation` para el brazo derecho, o `/robot/limb/left/suppress_gravity_compensation` para el brazo izquierdo.

De esta manera, un torque aplicado de 0 en todas las articulaciones, mantendrá el brazo en un estado de gravedad 0 si la compensación esta activa. De no estarlo, el brazo caerá en peso muerto.

2.2.7. Simuladores

V-REP

Virtual Robot Experimentation Platform (V-REP) [18] es un simulador robótico muy potente, con una gran cantidad de modelos predefinidos listos para simular, y una gran cantidad de opciones para configurar.

Gazebo

Al igual que V-REP, Gazebo [5] es un simulador de plataformas robóticas. Es menos potente, y tiene menos modelos predefinidos, pero está integrado con ROS, y el robot Baxter cuenta con un modelo listo para simular para el mismo, por lo que es la opción elegida para realizar las pruebas.

Problemas La versión del simulador en la que está implementada es la 2.2, mientras que la que se puede descargar ahora es la 7.1. Esto hace que no sea lo potente que debiera, y a la hora de realizar simulaciones utilizando el control por torques, el simulador no responde igual que el robot, por lo que su uso quedó limitado a las primeras pruebas que se hicieron en una primera aproximación al control por posición del robot.

2.3. Redes Neuronales

Una red neuronal artificial [1] [10] [13] es un conjunto de algoritmos de aprendizaje automático capaces de extraer modelos a partir de un conjunto de datos de aprendizaje. De esta manera, estos sistemas son capaces de emular la fuente generadora de datos y producir salidas coherentes a partir de entradas no vistas con anterioridad.

2.3.1. Topología

En función de la topología de la red, se contemplan dos tipos fundamentales:

Redes hacia adelante

Las conexiones entre las neuronas es de un solo sentido, de modo que no se forman bucles entre ninguna de las neuronas (figura ??). Las líneas que conectan las “neuronas” son pesos, y la interconexión entre una capa y otra se puede representar como una matriz de $m \times n$, donde m es el número de neuronas de la capa anterior, y n es el número de neuronas de la capa siguiente. De este modo, la entrada de cada capa no es sino la combinación lineal de las salidas de las capas anteriores.

Si las relaciones entre las capas sólo fueran combinaciones lineales, la red neuronal se podría reducir a una única matriz que interconectara la capa de entrada con la de salida. Lo que sucede es que cada neurona tiene una activación, que consistirá en una relación no lineal entre la entrada que percibe y la salida. Son estas no linealidades las que le confieren la capacidad de aprender parámetros nuevos, por lo que podrán ajustarse al espacio de búsqueda.

Activaciones Las activaciones más usadas son las siguientes.

Sigmoidea Consiste en una función cuyo rango va de 0 a 1. Esto permite interpretar su salida como una probabilidad. Es muy usada en tareas de clasificación (figura ??).

Sigmoidea “dura” Se trata de una aproximación de la función sigmoidea a trozos, tal y como se muestra en la figura ??.

Tangente hiperbólica Tiene un comportamiento parecido a la sigmoidea, pero su rango va de -1 a 1, y es simétrica. (figura ??).

Rectificador lineal (ReLU) Se trata de la función lineal rectificada. Es muy usada en redes neuronales profundas (explicadas más adelante) debido a las características de la derivada (figura ??).

Errores Para calcular el rendimiento de una red se utilizan los errores a la salida, que consiste en aplicar una función a los valores obtenidos y los deseados. Las funciones más comunes son las siguientes:

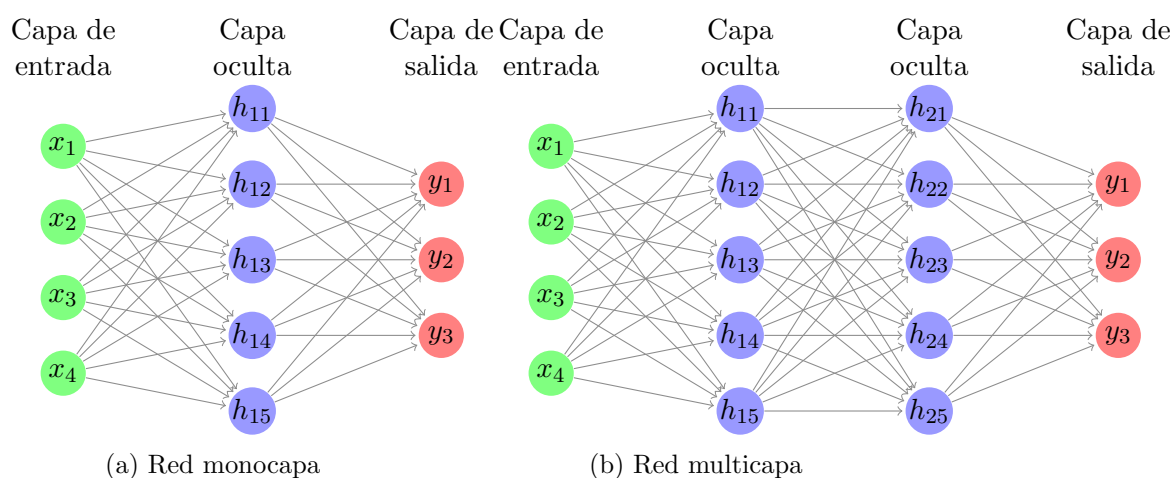


Figura 2.4: Redes neuronales de propagación hacia adelante

MAE El error absoluto medio (MAE) es la media del valor absoluto de la diferencia de los errores cometidos en cada neurona a la salida. Usado en problemas de regresión lineal (la salida es una curva función de los datos de entrada).

MSE El error cuadrático medio (Mean Squared Error) consiste en la media de los cuadrados de la diferencia de los errores cometidos en cada neurona a la salida. Se utiliza también en regresión lineal.


Entropía cruzada Su fórmula es $H(p, q) = -\sum_x p(x) \log q(x)$ y es usada en tareas de clasificación, ya que da un mayor sentido a la probabilidad que representa la salida de este tipo de redes.

Perceptron Fue el primer tipo de red neuronal. La manera de obtener las salidas es igual a la explicada anteriormente.


El entrenamiento de este tipo de red neuronal consiste en minimizar el error de los pesos (relaciones entre las neuronas). Esto significa que, suponiendo que hay un conjunto de pesos que permite obtener la salida correcta para cada una de las entradas, el perceptrón iterará sobre cada uno de los pesos hasta encontrar un subconjunto de estos pesos.

El problema radica en que puede no existir dicho conjunto, y por lo tanto el perceptrón no será capaz de encontrar los pesos.


Es por esto por lo que su uso queda restringido a problemas donde las características sean separables.




(a) Función sigmoidea



(b) Función sigmoidea "dura"



(c) Tangente hiperbólica



(d) Rectificador lineal

Figura 2.5: Activaciones

Propagación hacia atrás de errores Otra manera de entrenar la red, consisten en encontrar el conjunto de pesos que minimiza una función error, generada por los errores cometidos a la salida de la red.

Al contrario que en el perceptrón, este tipo de entrenamiento permite encontrar un mínimo local en el espacio de los pesos para el conjunto de datos, aunque estos no sean separables.

El algoritmo de actualización de los pesos usado es el de propagación hacia atrás de errores. Consiste en, a partir del error generado en la salida, se reduce cada uno de los pesos en función de la cantidad de error asociado a dicho peso. Para realizar este algoritmo, se requiere de las derivadas de los errores cometidos en cada neurona, a fin de obtener la relación entre el error final del que cada neurona es responsable.

Hay distintos tipos de algoritmos [21] que implementan la propagación hacia atrás de errores.

Descenso en gradiente Consiste en el algoritmo más sencillo. Dada la relación entre el error total y el generado en por cada peso, modifica el peso de manera proporcional a dicho error. Esto, visto en el espacio de los pesos con respecto al error total, significa descender por la curva en la dirección y sentido de mayor pendiente (de ahí el nombre).

Descenso en gradiente estocástico Es como el anterior, pero, en vez de calcular el error para todo el conjunto de datos de entrenamiento, se calcula el error en pequeños grupos y se aplica el algoritmo. Esto produce que el descenso no se produzca en la dirección de máxima pendiente del conjunto, sino del subconjunto. El método funciona porque la media de dichos descensos aproxima el descenso total. Al caso en el que el subconjunto es una sola muestra se le llama aprendizaje online.

Momentum Es una modificación al descenso en gradiente, en el que la dirección de descenso se ve alterada por los descensos producidos en iteraciones anteriores. Esto le da la característica de “velocidad” al punto de operación.

Adam La estimación adaptativa del momento hace uso de la técnica del momento, y adapta la cantidad de descenso en gradiente para cada uno de los parámetros a optimizar, de modo que, los parámetros cuyo rango de operación es más pequeño perciben cambios más pequeños en la actualización de su valor.

Redes recursivas

Las redes recursivas [16] difieren de las redes hacia delante en que las neuronas pueden conectarse entre sí hacia atrás (o consigo mismas), gene-

rando en la red una realimentación entre nodos que provoca que la salida de la red no dependa sólo de la entrada, sino del estado de la misma (que varía en función de su historia).

Tienen la capacidad de aprender de sistemas cuyo comportamiento cambia con el tiempo.

Redes recurrentes Es el tipo de red recursiva más básica. Consiste en un conjunto de neuronas (normalmente agrupados en una capa) cuya salida no depende solamente de las entradas provenientes de capas anteriores, sino que también dependen de las salidas de las neuronas en esa misma capa. De esta manera, el estado de la red cambia conforme cambian las salidas de esta capa.

LSTM Las redes de memoria a corto y largo plazo (Long Short Term Memory) [11][15] hacen uso de una unidad especial, que consiste en un conjunto de puertas que permiten el flujo de información a través de la neurona. En concreto, cuenta con 3 puertas:

- Puerta de entrada. Su valor varía de 0 a 1 y se multiplica al valor de la entrada de la activación.
- Puerta de salida. Igualmente, su valor varía de 0 a 1 y se multiplica al valor de la salida después de la activación.
- Puerta de olvido. Representa la cantidad del estado anterior que se mantiene.

Todas estas puertas son activaciones sigmoideas que se activan con las entradas de la celda y con el estado de la misma.

GRU Las celdas GRU (Gated Recurrent Unit) [4] son, al igual que las LSTM, celdas que hacen uso de puertas. Son más sencillas que las anteriores, y requieren menos cómputo, por lo que son más rápidas de entrenar. Cuentan con dos puertas en vez de tres: reinicio y actualización.

La salida es una interpolación lineal del estado anterior y el nuevo estado propuesto, el cual se calcula como una combinación de la entrada y el estado anterior (multiplicado por la puerta de reinicio). La puerta de actualización se calcula a partir del estado anterior y la entrada, al igual que la puerta de reinicio.

Propagación hacia atrás de errores en el tiempo El algoritmo de optimización de parámetros en el tiempo es el mismo usado en las redes hacia delante (propagación hacia atrás de errores), con la peculiaridad de que la red se desenrolla en el tiempo. Esto significa, que las neuronas realimentadas se interconectan entre sí en cada instante temporal (desenrollado).

Las pérdidas se calculan de la misma manera, calculando el error en cada instante temporal (si es que se tiene una salida en cada instante) y aplicando el algoritmo de propagación hacia atrás sobre cada neurona.

Esta es la principal razón por la que surgieron las celdas LSTM y GRU, ya que, haciendo uso nada más de las redes recurrentes, se tiene el problema de desvanecimiento y explotación de los pesos de la red [2]. Este fenómeno surge cuando la red se desdobra un número lo suficientemente grande como para que, al propagar hacia atrás el error, debido a la gran dimensionalidad de la red, el error llegue muy reducido (desvanecimiento) o muy amplificado (explotación), impidiendo que, alcanzado este punto, la red aprenda.

2.3.2. Regularización

Las redes neuronales son sistema capaces de aprender a extraer patrones de los datos que se le ofrecen. Por lo tanto, se podría pensar que una red lo suficientemente grande es capaz de extraer cualquier patrón que haya en los datos. Esto es ideal si contamos con una base de datos infinita, ya que cualquier discrepancia entre muestras se tomaría como ruido y la red no aprendería de éste. El problema es que no se puede aprender de una base de datos infinita (el tiempo de cálculo sería igualmente infinito), y no se puede obtener dicha base de datos.

Una vez asumido que no se puede disponer de esta base de datos, nos encontramos con el problema de que, en una base finita, podemos no tener representados todos los casos de estudio que nos interesan, esto es, que la base de datos no sea representativa de la realidad de la que se pretende aprender. En este caso, lo mejor que puede hacer la red es aprender de dichas muestras, y sería incapaz de generalizar para el conjunto no visto (o no visto lo suficiente).

También nos encontramos con que cada muestra por sí misma puede contener ruido (de los sensores, de un error en el proceso de obtención...). En este caso, si no se toman medidas, la red aprenderá también estos patrones, lo que reducirá aumentará el error cuando se enfrente a muestras que no ha visto antes (y sobre las que el ruido ha influido de manera distinta).

Es por esto, por lo que se requieren de técnicas de regularización, para evitar el sobreentrenamiento de la red (overfitting). Algunas de estas técnicas son las siguientes.

Infradimensionamiento de la red

La primera medida que se puede tomar es ajustar el tamaño de la red al problema que se esté abarcando. De esta manera, se elimina el problema de base de que las redes más grandes son las que mejor encuentran patrones (en este caso de estudio, de ruido).

L2

El problema del sobredimensionamiento es que las neuronas se especializan demasiado (capaces de reconocer el ruido). Esta especialización se da debido a que algunos pesos de interconexión de neuronas se vuelven muy altos, eliminando la influencia que tienen el resto de entradas en una misma neurona.

Una solución a este problema es añadir un error proporcional al cuadrado de los pesos de cada neurona (error L2). De esta manera, los pesos altos (especializados) aumentarán el error, y en el paso de propagación hacia atrás de errores se reducirá dicho peso.

L1

La regularización L1, al igual que la L2 [14], consiste en la aportación de los pesos al error, pero a diferencia de ésta, esta aportación es lineal proporcional (no cuadrática). Esto ayuda a seleccionar un conjunto de neuronas, que se especializarán, pero, al ser un número reducido de ellas, esta especialización promoverá el aprendizaje de los patrones más importantes de los datos de entrenamiento, y por lo tanto, la eliminación del ruido.

Dropout

Dropout [8] es una técnica de regularización que se basa en el hecho de que, la media ponderada de un conjunto de redes neuronales, cada una especializada en un subconjunto de datos, genera unos resultados mejores que cada una de las redes individualmente. Esto se debe a que cada red puede haber adquirido un error distinto, pero al juntarlas, este error disminuye.

El problema es que entrenar redes neuronales es un proceso computacionalmente costoso. Es por esto por lo que esta técnica propone realizar dicha media en la fase de entrenamiento. Para ello, en la fase de propagación hacia adelante, anula cada neurona con una probabilidad p , de modo que la salida va a depender de un subconjunto de las neuronas de la red (entre las cuales pueden estar o no las neuronas especializadas). De esta manera, se consigue que las dependencias con las neuronas más especializadas se reparta sobre varias neuronas, de modo que se reduce el error, al depender de varias neuronas, cada una con su versión reducida del error.

2.3.3. Aprendizaje profundo

Aprendizaje profundo (Deep Learning) [22][9] es un conjunto de técnicas usadas sobre las redes neuronales que le permiten alcanzar resultados nunca antes conseguidos en el campo del aprendizaje automático.

En un sentido amplio, el aprendizaje profundo consiste en una red neuronal con un gran número de capas y un gran número de neuronas por capas.

Esto le da la capacidad de abarcar cualquier problema, pero también tiene el problema de que la red, de no tomar las medidas adecuadas, aprenderá incluso el error que hay en la base de datos de entrenamiento (overfitting).

Este error se disminuye haciendo uso de la técnica de regularización dropout, utilizado en conjunción con el error L2 y/o el error L1.

Este tipo de redes son realmente potentes cuando se entrenan con grandes bases de datos de entrenamiento. El problema de estas bases de datos, es que para realizar el algoritmo de propagación hacia atrás de errores, es necesario calcular el error de cada neurona, y para ello hay que calcular la derivada y la aportación de cada neurona al error. Esto supone una gran cantidad de recursos (tanto de procesamiento, realizado en GPU, como de memoria) que en ocasiones no se puede abarcar. Para solucionar este problema, se utilizan algoritmos de propagación hacia atrás de errores basados en la división de la base de entrenamiento en grupos (descenso en gradiente estocástico).

Como se ha comentado, hay que calcular las derivadas para conocer la aportación de cada neurona al error. Esto supone un gran coste computacional, por lo que se utilizan funciones no lineales con derivadas fáciles de calcular, como las activaciones relu o la sigmoide “dura”.

2.3.4. Evaluación

Para evaluar el rendimiento de la red neuronal, se divide la base de datos en dos conjuntos, uno de entrenamiento y otro de test. El primero servirá para entrenar la red, cada uno de los pesos. El segundo servirá para calcular el error que comete esa red sobre un conjunto de datos no vistos en el entrenamiento.

Además, se puede dividir los datos en un tercer conjunto, llamado de validación [12], para ajustar parámetros de la red, como número de neuronas por capa, número de capas, proporción usada en dropout, en L1, L2, distintas topologías... El motivo por el que no se puede usar el conjunto de test para este fin y ha de utilizarse uno distinto, es debido a que este conjunto lo vamos a utilizar para tomar decisiones sobre la red basadas en el rendimiento que se obtiene con dicho conjunto. Es por esto, por lo que el error obtenido en el conjunto de test (de usarse como de validación) no sería válido, ya que la red ha sido diseñada para adaptarse a dicho conjunto, y por lo tanto, a la hora de enfrentarse a datos nuevos, no desempeñaría con la eficacia esperada.

2.3.5. Herramientas

Diseñar los algoritmos mencionados no es tarea fácil, y mucho menos hacerlo con la eficiencia que se necesita para que estas técnicas sean viables. Es por esto por lo que existen diversas plataformas de diseño de redes neuronales, con los algoritmos de propagación hacia atrás de errores, las topologías, activaciones y métodos de regularización ya implementadas.

Entre ellas se encuentran *Theano*, *Tensorflow* [23], *Caffe* [3], *Torch* [20]... Además, contamos con librerías que, sobre estas anteriores, ofrecen una capa de abstracción para diseñar y entrenar redes neuronales profundas, como Keras [6] y Lasagne.

Las librerías usadas en este trabajo son *Tensorflow* y *Keras*, debido a que están escritos en Python (facilitando la integración con la API de Baxter, así como *rospy*) y que cuentan con una gran comunidad detrás que hace sencillo su aprendizaje y la resolución de problemas que van surgiendo conforme se va desarrollando.

Tensorflow

Creada por Google, esta librería se basa en la descripción de la red (gráficos)

Keras

2.4. Controladores

2.4.1. Error distal

2.4.2. Control realimentado

2.4.3. Control Anticipativo

Capítulo 3

Diseño experimental y resultados

En este capítulo se explicarán las decisiones tomadas en cuanto al diseño del experimento con el fin de alcanzar los objetivos previamente mencionados, así como los resultados obtenidos de dicho experimento.

3.1. Diseño experimental

Una vez estudiados los mecanismos de control del Baxter, se procederá a extraer una base de datos del control por posición, así como diseñar una red neuronal capaz de aprender de este controlador.

3.1.1. Extracción de base de datos

La base de datos consistirá en las posiciones, velocidades y torques registradas por el robot, así como de las órdenes enviadas sobre la posición y la ratio de velocidad deseadas.

Para ello, haremos uso de la interfaz para el lenguaje Python que ofrece Baxter, así como de la herramienta `rosvbag`.

Ejecución

El espacio vectorial de las siete dimensiones formadas por cada una de las articulaciones se muestreará de manera uniforme, a fin de obtener una base de datos representativa del controlador que estamos aprendiendo. Esto significa que, para cada movimiento, se elegirán siete posiciones objetivo (una por articulación) de acuerdo a una distribución uniforme sobre el rango de cada articulación. De igual manera se elegirá una ratio de velocidad objetivo con distribución uniforme entre 0 y 1. El tiempo máximo empleado para cada movimiento será de 15 segundos, tiempo suficiente para permitir

el movimiento entre puntos distantes entre sí a una velocidad baja, y por lo tanto, para todos los movimientos.

Tratamiento

Una vez obtenida la base de datos, se prepara para la fase de entrenamiento y evaluación de la red neuronal.

Ficheros .bag El primer paso consiste en transformar la base de datos en tipos de datos que entienda el lenguaje de programación Python.

Los ficheros obtenidos con `roscap` tienen la extensión `.bag`, y consisten en ficheros conteniendo mensajes sobre los que se iteran. De esta manera, iteramos sobre cada mensaje y leemos su contenido, que consiste en el tema del cual proviene el mensaje, una marca temporal de su recepción por `roscap`, y del mensaje en sí mismo.

La marca temporal corresponde al tiempo del reloj interno del ordenador en el cual se recibe el mensaje. Dado que la conexión entre el robot y el ordenador se realiza por `tcp/ip`, este tiempo diferirá del de generación en el robot. Para paliar con este problema, ROS dispone una marca temporal dentro del cuerpo del mensaje con el instante de creación del mensaje en el robot (de acuerdo a su reloj interno), además de un número de secuencia para ordenar los mensajes en el ordenador.

Error en frecuencia Gracias a esta información, se percibió un error en frecuencia entre el reloj del ordenador y el del robot. Esto significa que, a una frecuencia de generación de mensajes de 100 Hz, el ordenador generó 100 posiciones y velocidades deseadas por segundo (suponiendo que es el que tiene el reloj ajustado correctamente), mientras que el robot generó 99 posiciones, velocidades y torques actuales. Para solventar este problema, en primera instancia se representó gráficamente la diferencia de mensajes obtenidos por parte del ordenador y el robot en función del tiempo (figura 3.1a).

Como se puede observar, esta diferencia crece con el tiempo, lo que significa que el ordenador genera mensajes a mayor velocidad que el robot. Es cuando el ordenador deja de generar mensajes cuando esta diferencia cae en picado, momento en el cual, los mensajes generados por el robot dejarán de corresponderse con las posiciones deseadas y pasarán a corresponderse con las posiciones, velocidades y torques del robot manteniendo la última posición alcanzada.

Por lo tanto, el objetivo será encontrar el momento en el que ocurre dicha bajada, es decir, el pico. El problema surge cuando la señal no es monótona, sino que, como se observa en la figura 3.2a, crece y decrece en intervalos temporales pequeños (debido a la naturaleza a ráfagas de la señal). Para paliar con este inconveniente, se realiza un filtrado paso baja (con un filtro

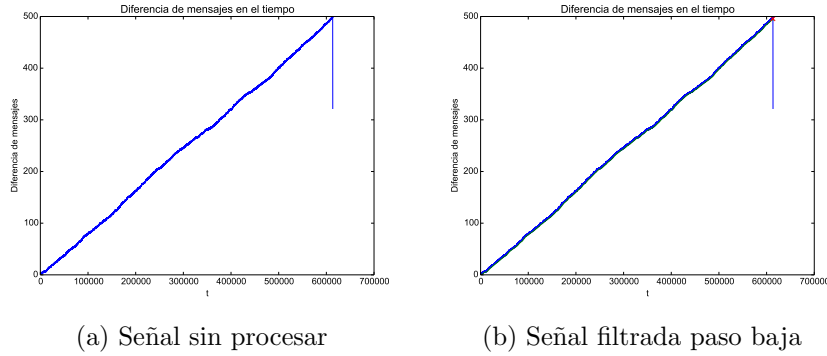


Figura 3.1: Diferencia de mensajes recibidos del ordenador y del robot

de media móvil) que elimine dicha componente frecuencial. El resultado es el que se observa en las figuras 3.1b y 3.2b. A partir de esta señal, solo queda seleccionar el valor máximo de la misma. El valor obtenido es el número de mensaje recibido hasta el cual los mensajes son válidos.

Dado que el control lo vamos a realizar desde el ordenador, adaptamos los mensajes recibidos al mismo. Esto lo hacemos mediante interpolación lineal en las posiciones, velocidades y torques recibidos.

De esta manera, se obtienen vectores de la misma longitud (en el tiempo) tanto enviados como recibidos.

Ráfagas También se percibió la llegada a ráfagas en los mensajes provenientes del robot. Esto no supone un problema para preparar los datos, pero sí lo es a la hora de realizar un controlador realimentado que requiere la información que proporciona el robot sin desfases. El controlador propuesto en este trabajo no es realimentado, pero de serlo, una posible solución




Figura 3.2: Detalle de diferencia de mensajes recibidos del ordenador y del robot

sería implementar el controlador en el propio robot (no ejecutarlo en el ordenador), aunque para ello habría que tomar nuevamente la base de datos o ajustarla a la frecuencia de generación de mensajes del robot. Otra posible solución consistiría en un predictor de posiciones y velocidades que ofrezcan al controlador esta información cuando no disponga de la misma. Por ejemplo, supongamos que en un instante concreto, llega una ráfaga de tres posiciones, velocidades y torques provenientes del robot. Esto significa que, dos instantes anteriores, el ordenador no ha obtenido ninguna información, por lo que la última posición, velocidad y torques conocidos son los obtenidos hace dos instantes temporales. En este caso, el predictor generaría 2 posiciones y velocidades (los torques serían la salida del sistema) para los instantes temporales que no disponen de información directa.

3.1.2. Red Neuronal

A continuación se estudia la viabilidad de la implementación de un controlador a partir del propio de Baxter basado en redes neuronales de aprendizaje profundo.

Viabilidad

El primer problema a enfrentarse es el de demostrar que la red neuronal es capaz de aprender algo de los datos extraídos del controlador del Baxter. Por la capacidad de detectar colisiones sabemos que es un sistema realimentado, posiblemente con un controlador PID.

Se podría realizar un controlador donde el modelo dinámico (controlador anticipativo) fuera desempeñado por la red neuronal, y donde la realimentación fuera desempeñada por el controlador PID. También podría implementarse la realimentación como otra red neuronal, pero ambas aproximaciones tienen el problema de enfrentarse a la realimentación y al tiempo real (a una frecuencia de realimentación de 100Hz). Las redes neuronales profundas tienen el problema de ser pesadas en el cómputo (debido a las no linealidades usadas para la activación de las neuronas), poniendo en riesgo la capacidad de afrontar el problema en tiempo real.

Es por esto por lo que se decide hacer un controlador sin realimentación, donde los datos de entrada sean posiciones objetivo, posiciones en el momento de iniciar el movimiento, y velocidad objetivo, siendo los de salida una sucesión de torques a aplicar para alcanzar la posición deseada.

Para ello se elige una arquitectura basada en redes neuronales realimentadas, ya que las no realimentadas tienen la limitación de generar la misma salida ante la misma entrada, y siendo nuestra entrada única (debido a que el sistema no es realimentado), generaríamos siempre la misma salida, en vez de la sucesión de torques deseada.

Nos encontramos con el problema de, si el controlador implementado

por Baxter es realimentado, ¿puede un modelo no realimentado aprender de este? El controlador del Baxter tiene una estructura como la mostrada en la figura 3.3. El funcionamiento es el siguiente:

1. El controlador realimentado genera una señal torque a partir de la realimentación de posición del sistema y la posición deseada.
2. El controlador anticipativo tiene en cuenta el modelo interno del robot y ajusta la señal de control generada por el controlador realimentado.
3. Se transmite la señal y el robot genera el torque enviado.
4. La aplicación genera una nueva posición que es recibido por los sensores y usado para la realimentación.

El controlador realimentado no es más que un sistema (lineal o no) que a ciertas entradas genera ciertas salidas (en función de su historia o no). El controlador anticipativo igualmente es un sistema que tiene en cuenta el modelo dinámico del robot, y por lo tanto los dos sistemas son reproducibles por una red neuronal. Por último, tenemos la realimentación, y es en este aspecto, donde la red neuronal tendrá que aprender a producir estimaciones de la salida provocada (posiciones de las articulaciones) al aplicar los torques.

Por lo tanto, la viabilidad de nuestro controlador depende de la capacidad de la red para generar dicha estimación de la realimentación.

Es por ello por lo que se utilizarán redes neuronales recurrentes, ya que tanto el controlador realimentado, como el anticipativo, como la realimentación en sí misma son sistemas que dependen de la historia de las señales de las que dependen, y esto es exactamente lo que hacen este tipo de redes.

3.2. Resultados

3.2.1. Base de datos

Por motivos de tiempo de entrenamiento, así como para aislar potenciales problemas a la hora de realizar el entrenamiento, se han tomado distintas




Figura 3.3: Sistema de control de Baxter

bases de datos.

Todas las articulaciones El grueso de nuestra base de datos se ha realizado a partir del movimiento de todas las articulaciones, a distintas velocidades, con un tiempo de espera de 15 segundos.

Una articulación Se ha aislado el problema del tamaño del espacio a muestrear (las siete articulaciones, cada una con su rango de movimiento) reduciéndolo a una de las siete articulaciones en todo su rango de movimiento. El resto de las articulaciones se mantienen quietas en la posición cero.

5 segundos En lugar de limitar el tiempo para cada movimiento a 15 segundos, se limita a 5 segundos, para así aislar el problema de desdoblar la red en un intervalo de tiempo tan alto ($15\text{ s} * 100\text{ Hz} = 1500\text{ muestras}$).

0.5 seg. ratio vel. 1 Es el caso más simple para entrenar la red. Se mueve una sola articulación (el resto se ubican en la posición 0) a máxima velocidad (relación de velocidad 1) durante 0.5 segundos. De esta manera obtenemos una base de datos muy amplia (más de 120 posiciones objetivo por minuto) con el problema del tamaño del espacio y del desdoblamiento temporal muy limitados.

Adicionalmente, se ha obtenido un conjunto de datos con combinaciones de distintas articulaciones, así como del brazo con las pinzas anexas para un tiempo máximo de 15 segundos y velocidad variable.

Capítulo 4

Conclusiones

4.1. Trabajo realizado

4.2. Objetivos alcanzados

4.3. Trabajo futuro

Bibliografía

- [1] Yaser S Abu-Mostafa, Malik Magdon-Ismail, and Hsuan-Tien Lin. *Learning from data*, volume 4. AMLBook Singapore, 2012.
- [2] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE transactions on neural networks*, 5(2):157–166, 1994.
- [3] BVLC. *Web principal de Caffe*, (último acceso 15 de Enero 2016). URL: <http://caffe.berkeleyvision.org/>.
- [4] Junyoung Chung, Caglar Gulcehre, KyungHyun Cho, and Yoshua Bengio. Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*, 2014.
- [5] Open ended Neuro-Electronic Intelligent Robot Operating System. *Página principal de Gazebo*, (último acceso 24 de Febrero 2016). URL: <http://gazebo-sim.org/>.
- [6] Open ended Neuro-Electronic Intelligent Robot Operating System. *Página principal de Keras*, (último acceso 5 de Diciembre 2016). URL: <https://keras.io/>.
- [7] Open Source Robotics Foundation. *Página principal de ROS*, (último acceso 6 de Abril 2016). URL: <http://www.ros.org/>.
- [8] Yarín Gal. A theoretically grounded application of dropout in recurrent neural networks. *arXiv preprint arXiv:1512.05287*, 2015.
- [9] Google. *Apredizaje profundo*, (último acceso 15 de Julio 2016). URL: <https://www.udacity.com/course/deep-learning--ud730>.
- [10] Geoffrey Hinton. *Redes neuronales para aprendizaje automático*, (último acceso 8 de Octubre 2016). URL: <https://www.coursera.org/learn/neural-networks>.
- [11] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.

- [12] Ron Kohavi et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Ijcai*, volume 14, pages 1137–1145, 1995.
- [13] Andrew NG. *Aprendizaje automático*, (último acceso 20 de Septiembre de 2015). URL: <https://www.coursera.org/learn/machine-learning>.
- [14] Andrew Y Ng. Feature selection, l_1 vs. l_2 regularization, and rotational invariance. In *Proceedings of the twenty-first international conference on Machine learning*, page 78. ACM, 2004.
- [15] Christopher Olah. *Entendiendo las redes LSTM*, (último acceso 17 de Septiembre 2016). URL: <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>.
- [16] Christopher Olah. *La eficacia irracional de las redes neuronales recurrentes*, (último acceso 17 de Septiembre 2016). URL: <http://karpathy.github.io/2015/05/21/rnn-effectiveness/>.
- [17] Gill A Pratt and Matthew M Williamson. Series elastic actuators. In *Intelligent Robots and Systems 95. 'Human Robot Interaction and Cooperative Robots', Proceedings. 1995 IEEE/RSJ International Conference on*, volume 1, pages 399–406. IEEE, 1995.
- [18] Coppelia Robotics. *Página principal de V-REP*, (último acceso 10 de Enero 2016). URL: <http://www.coppeliarobotics.com/index.html>.
- [19] Rethink Robotics. *Página principal de Baxter*, (último acceso 13 de Mayo 2016). URL: <http://www.rethinkrobotics.com/baxter/>.
- [20] Koray Ronan, Clement and Soumith. *Web principal de Torch*, (último acceso 14 de Enero 2016). URL: <http://torch.ch/>.
- [21] Sebastian Ruder. *Diferencias entre algoritmos de optimización*, (último acceso 10 de Noviembre 2016). URL: <http://sebastianruder.com/optimizing-gradient-descent/>.
- [22] Jürgen Schmidhuber. Deep learning in neural networks: An overview. *Neural Networks*, 61:85–117, 2015.
- [23] Google Brain Team. *Página principal de Tensorflow*, (último acceso 1 de Octubre 2016). URL: <https://www.tensorflow.org/>.

